ICT – UNIFESP
Introdução às Redes Neurais Artificiais
Projeto 5 – VAE

Arthur Losano de Araujo Silva
RA: 163564

1 Introdução

O projeto treina dois autoencoders variacionais no Fashion-MNIST, com espaço latente de 2 e de 8 dimensões. A largura de cada rede é a de menor loss na validação. O espaço de 2 dimensões é desenhado direto; o de 8 é projetado por PCA. Os rótulos só colorem esses gráficos. As perguntas são se há clusters, se os rótulos se separam e quanto da variância a projeção ilustra.

O conjunto tem 70 mil imagens de 28×28 pixels em escala de cinza e dez classes de roupa: 60 mil de treino e 10 mil de teste. Cada pixel foi dividido por 255. Da parte de treino, 6 mil imagens, 600 de cada classe, formam a validação, e 54 mil ajustam os pesos. O teste fica reservado aos gráficos. A rede recebe o vetor de 784 posições.

2 Método

2.1 Autoencoder variacional

O codificador não devolve um ponto. Para cada imagem x, produz a média μ e o logaritmo da variância $\log \sigma^2$ de uma gaussiana. A amostra usada pelo decodificador é obtida pelo truque de reparametrização,

$$z = \mu + \sigma \odot \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, I), \tag{1}$$

em que $\odot$ é o produto coordenada a coordenada. O acaso fica em ε, e o gradiente atravessa μ e σ.

A função de custo de cada imagem é a soma do erro de reconstrução com a divergência de Kullback–Leibler em relação à gaussiana padrão:

$$\mathcal{L}(x) = \|x - x'\|^2 + \mathrm{KL}\big(\mathcal{N}(\mu, \sigma),\, \mathcal{N}(0, I)\big). \tag{2}$$

A primeira parcela é a soma dos quadrados das diferenças pixel a pixel. A segunda tem forma fechada,

$$\mathrm{KL} = \frac{1}{2} \sum_{j=1}^{d} \left(\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2 \right), \tag{3}$$

com $d = 2$ ou $d = 8$. A loss do lote é a média de $\mathcal{L}(x)$ sobre as imagens do lote. As duas parcelas foram registradas em separado. A seleção usou a soma.

Na validação, o decodificador recebe μ, sem sortear ε. O número deixa de oscilar por causa do acaso, e a comparação entre topologias fica estável. Os gráficos também usam μ: cada ponto é o centro da nuvem daquela imagem.

2.2 Arquitetura e seleção

A rede é um perceptron de múltiplas camadas, com ReLU nas camadas ocultas e sigmoide na saída. O decodificador repete as larguras do codificador na ordem inversa. Foram comparadas duas topologias, $784 \to 256 \to 128$ e $784 \to 512 \to 256$, em cada dimensão latente. A taxa de aprendizado ficou fixa, para a escolha ser a da topologia.

O otimizador foi Adam, com taxa 10^{-3} e lotes de 128 imagens. Os quatro treinos curtos usaram a mesma semente e duraram 15 épocas. Em cada dimensão latente, venceu a largura de menor loss total na validação. Esse modelo continuou o treino a partir da melhor época da busca, com parada depois de cinco épocas sem melhora. O estado gravado é o da menor loss de validação, não o da última época.

Os dois estudos não foram reduzidos a um único vencedor. Um vetor de dois números não dispõe da mesma capacidade de reconstrução que um de oito. Cada configuração responde a uma parte do enunciado: a de 2 dimensões é desenhada direto, e a de 8 dimensões é projetada.

3 Resultados

3.1 Topologia escolhida

A Tabela 1 reúne a melhor época de cada treino curto. Nas duas dimensões, a melhor época da busca caiu na época 13, exceto na rede mais larga com z de 8 dimensões, cuja menor loss ocorreu na época 15.

Tabela 1: Menor loss de validação na busca de 15 épocas. Em negrito, a topologia retida em cada dimensão latente.

z	Largura	Loss	Reconstrução	KL
2	$256 \to 128$	25,84	21,05	4,79
2	$512 \to 256$	**25,36**	20,54	4,83
8	$256 \to 128$	**21,55**	14,53	7,01
8	$512 \to 256$	21,91	15,02	6,89

A rede mais larga venceu para z de 2 dimensões. A mais estreita venceu para z de 8. Dentro de cada dimensão, a diferença de loss ficou em torno de 0,5. A diferença relevante aparece entre as dimensões: a reconstrução passa de cerca de 20,5, com dois números, para cerca de 14,5, com oito. A KL sobe de cerca de 4,8 para cerca de 7,0, porque há mais coordenadas para manter próximas da gaussiana padrão.

Depois da continuação do treino, a loss de validação do modelo retido ficou em 24,86 para $z = 2$ e em 20,78 para $z = 8$. A parada antecipada encerrou esses treinos nas épocas 26 e 36. As curvas da Figura 1 mostram treino e validação descendo juntos. A validação não sobe enquanto o treino continua caindo. A reconstrução diminui e a KL aumenta: a rede passa a usar o espaço latente, e a penalidade da gaussiana cresce junto.

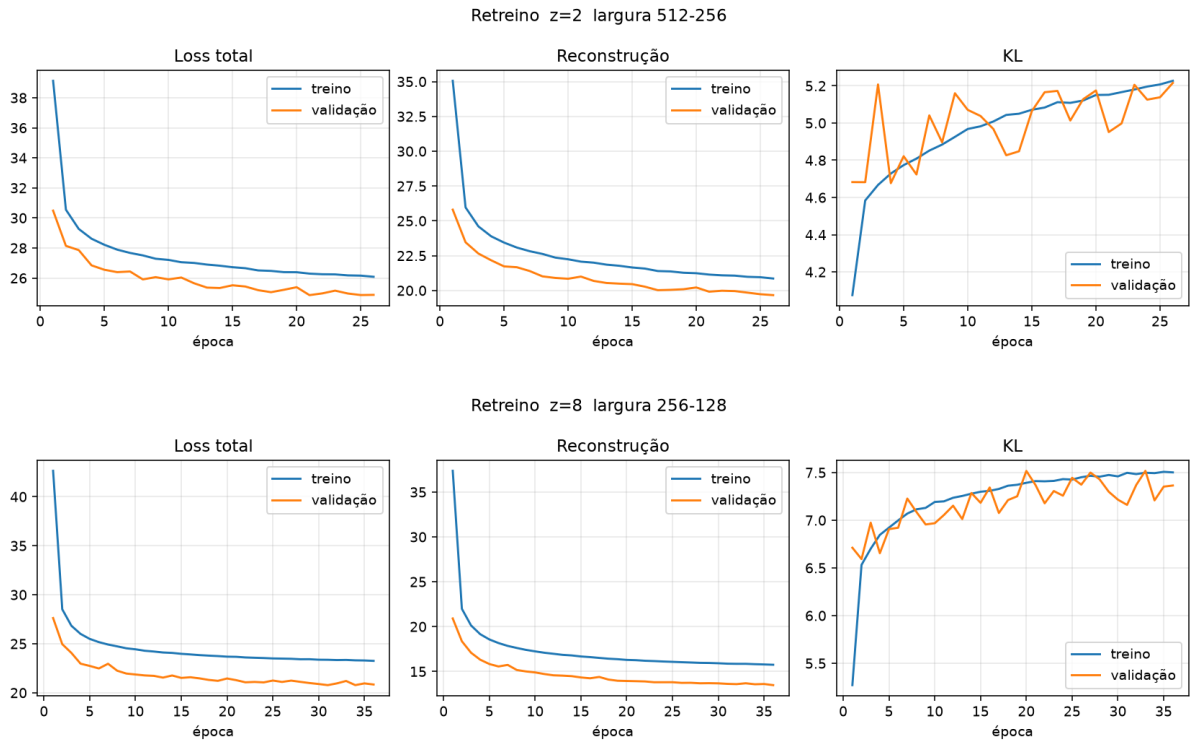


Figura 1: Loss total, reconstrução e KL ao longo do treino dos modelos retidos. Acima, $z = 2$, largura $512 \to 256$. Abaixo, $z = 8$, largura $256 \to 128$.

3.2 Reconstrução e geração

A Figura 2 compara, nas dez primeiras imagens de teste, o original e a reconstrução a partir de μ. Com dois números, a silhueta permanece e o detalhe desaparece: a estampa da camisa vira uma mancha e a bolsa vira um retângulo. Com oito números, o contorno fica um pouco mais fiel, em acordo com a queda da parcela de reconstrução, e a imagem continua borrada. Estampa e textura não cabem nesses gargalos.

A Figura 3 percorre o plano latente de 2 dimensões de -3 a 3 em cada eixo. Células vizinhas trocam de peça aos poucos, de calça para camisa, sapato e bolsa. O espaço está preenchido, que é o efeito procurado com a divergência KL.

3.3 Espaço latente

A Figura 4 junta as três leituras do modelo treinado. No topo, amostras do modelo de 8 dimensões obtidas com z sorteado de $\mathcal{N}(0, I)$, imagens que não estavam no arquivo. Abaixo, o μ das imagens de teste: primeiro nas duas coordenadas do modelo de 2 dimensões, depois na projeção do modelo de 8. A cor é o rótulo, usado somente na visualização.

A análise de componentes principais foi aplicada aos oito números de μ, já centralizados, por decomposição em valores singulares. A variância de cada componente é a parcela correspondente dos autovalores da matriz de covariância. A primeira componente explica 23,9% dessa variância e a segunda explica 22,9%. As duas juntas explicam 46,8%.

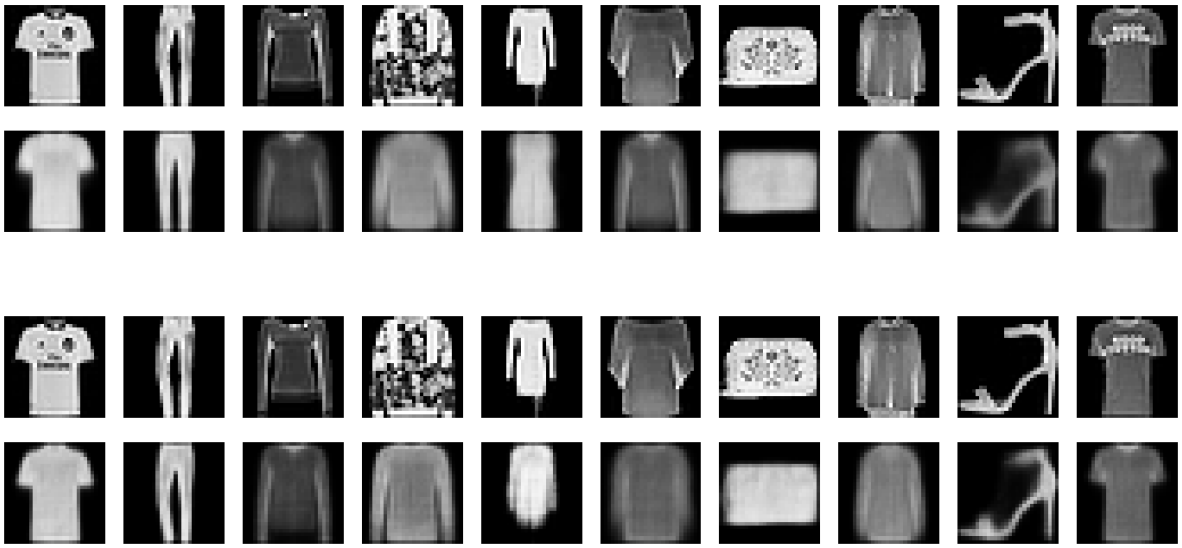


Figura 2: Originais de teste na primeira linha e reconstruções na segunda. Acima, o modelo com $z = 2$. Abaixo, o modelo com $z = 8$.

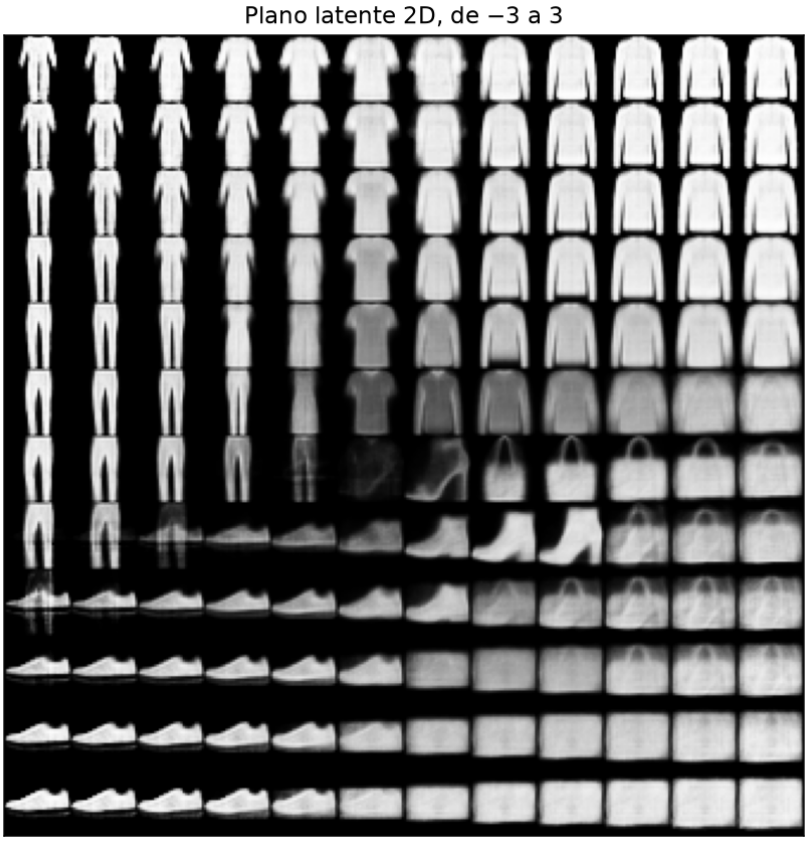


Figura 3: Decodificação de uma grade regular no plano latente de 2 dimensões, com cada eixo variando de -3 a 3.



Figura 4: Amostras geradas com $z = 8$ e espaço latente no conjunto de teste. No centro, as duas coordenadas do modelo com $z = 2$. Abaixo, a projeção por PCA do modelo com $z = 8$, com a variância explicada pelas duas componentes.

4 Discussão

4.1 Há formação de clusters?

Sim, nos dois gráficos, com nitidez diferente.

No espaço de 2 dimensões os pontos saem da origem em braços, em vez de formar uma nuvem única. Calça ocupa a esquerda. Bolsa ocupa o alto à direita. Tênis ocupa o alto à esquerda. Camiseta desce a partir da origem. Vestido fica embaixo à esquerda. Pulôver, casaco e camisa dividem o braço de baixo à direita.

No plano das duas componentes principais os agrupamentos continuam, mais difusos. Calça segue isolada à esquerda. Sandália e tênis ocupam o alto. Bolsa puxa para baixo à direita. O centro mistura as roupas de cima. Parte dessa mistura vem do achatamento: o plano conserva 46,8% do espalhamento dos oito números.

4.2 Há separação dos rótulos?

A separação é parcial nos dois espaços.

Calça e bolsa ocupam regiões próprias. Os calçados se afastam das roupas e ficam vizinhos entre si. No modelo de 2 dimensões, tênis, sandália e bota formam três cunhas encostadas. Camiseta, pulôver, casaco e camisa não se separam. Vestido encosta na calça e na camiseta. Peças de silhueta parecida permanecem próximas, o que é coerente com um treino que só viu pixels.

A separação visível é mais clara no latente de 2 dimensões, treinado para organizar todas as imagens em duas coordenadas. No desenho do modelo de 8 dimensões ela fica mais fraca. Essa frase descreve o plano da projeção. Uma separação que exista nos outros seis eixos não aparece na figura.

4.3 A projeção ilustra quanto da variância?

A projeção ilustra 46,8% da variância do espaço de 8 dimensões: 23,9% na primeira componente e 22,9% na segunda. Menos da metade do espalhamento dos oito números cabe no gráfico. A figura é um corte desse espaço, não um retrato completo.

5 Conclusão

Foram treinados dois VAEs em MLP no Fashion-MNIST. A validação escolheu topologias diferentes para cada tamanho de z: $512 \to 256$ com duas dimensões latentes e $256 \to 128$ com oito. O modelo de oito dimensões reconstrói melhor, com loss de validação de 20,78 contra 24,86, e o ganho está na parcela de reconstrução.

O espaço de 2 dimensões apresenta clusters e separa calça, bolsa e o grupo dos calçados. Camiseta, pulôver, casaco e camisa permanecem misturados. A grade desse plano gera peças intermediárias de forma contínua. A projeção do espaço de 8 dimensões conserva 46,8% da variância e mostra os mesmos grupos com menos nitidez.